

Question 1)

ایده اصلی الگوریتم "mini batch kmeans" این است که در هر iteration، از data، sample های به عنوان batch های رندم و کوچک وی باستانی fix و مشخصی را انتخاب می کند تا آن تعداد memory ذخیره کند. در iteration بعدی، sample های رندم جدیدی را انتخاب می کند و به همین ترتیب، در هر iteration، cluster update می شود تا در نهایت همگرایی (convergence) رخ دهد.

در واقع، در این الگوریتم، کلاس ها توسط ترکیب قطی و معی از prototype و data، update می شوند و یک learning rate که با افزایش تعداد iteration ها کاهش می یابد، به آن ها اعمال می شود.

$$\text{learning rate} = \frac{1}{\# \text{ data assigned to the clusters}}$$

به هر دور، همگرایی با عدم تغییر در کلاس ها رخ می دهد. همین با افزایش تعداد cluster ها و تعداد data های خوشه بندی شده، مقدار زمان محاسبه خوشه بندی در محاسبات نیز افزایش می یابد.

زمان (s) runtime در الگوریتم mini-batch kmeans نسبت به الگوریتم kmeans در هر iteration و با افزایش data های خوشه بندی شده، مشخصاً کمتر است. در واقع چون به ازای update کردن cluster ها از روش gradient descent استفاده می شود، الگوریتم سریعتری نسبت به روش kmeans خواهد داشت.

در عین حال، مشکل الگوریتم mini batch kmeans این است که (یعنی رندم بودن نسبت به الگوریتم kmeans) نتایج مختلفی در خوشه بندی کردن data نسبت به الگوریتم kmeans عادی می دهد. در واقع با تکرار نتایج clustering در این دو الگوریتم، مشاهده می کنیم که نتایج وجود دارند که توسط الگوریتم mini batch kmeans، در خوشه های متفاوتی با خوشه های الگوریتم kmeans قرار می گیرند.


Question 2)

در الگوریتم kmeans، در صورت عادی centroid ها به صورت رندم انتخاب می شوند ولی اگر این انتخاب به حالت بهینه آن ها نزدیک نباشد، پس الگوریتم خوشه بندی باید در تعداد iteration های بیشتری انجام شود تا به همگرایی برسد و این یعنی runtime \uparrow efficiency \downarrow .

مثال instance based

Centroid را بهتر کنیم در ابتدا Initialization

و یا k را به صورت optimal انتخاب کنیم. که در این حالت می توانیم از k -Elbow روشی برای انتخاب k بهینه استفاده کنیم که نفوذ این است که مقدار فضای clustering را به حسب هر k نشان می دهد و در این، در نقاطی که تغییرات ناگهانی در Error رخ می دهد، Elbow بهترین k را نشان می دهد.



برای حالت انتخاب بهینه centroids صادر ابتدا (یا همان روش های Improved centroids initialization) به جاس اینک centroids ها را رندم انتخاب کنیم، می توانیم از روش The Naive Sharding Centroid Initialization Algorithm استفاده کنیم.

در این روش، بدین صورت عمل می کنیم:

step 1: یک ستون جدید به data اضافه می کنیم و ویرانه هر سطر آن، مجموع داده های آن سطر را وارد می کنیم.

step 2: داده ها را بر اساس ستون جدید را از صند به نزولی، sort می کنیم.

step 3: کلاس ها $k-1$ تا k از بالا به پایین جدا می کنیم و به هم قسمت اصطلاحاً یک "Shard" می گردیند.

step 4: برای هم shard، مجموع داده هایش (به غیر از ستونی که در step 1 درست کردیم) و نیز mean آنها را حساب کرده و در یک سطر جدید وارد می کنیم. این سطر جدید یک centroid خوب است.

step 5: هم centroid در هم shard را به centroid ها جدید اضافه می کنیم.

step 6: return (centroids)

روش دیگر، گوییم ++ kmeans است. که به صورت زیر کار می کنه:

step 1: اولین centroid از روش data point ها به صورت رندم انتخاب می شه.

step 2: برای هم data point، فاصله اش را از نزدیک ترین centroid قبلی پیدا می کنیم.

step 3: centroid بعدی را محور انتخاب می کنیم که اقبال انتخاب شدنش متناسب با فاصله اش از نزدیک ترین centroid انتخاب شده (نقطه ای که بیشترین فاصله از centroid قبل داشته باشد، احتمالاً به عنوان centroid بعدی انتخاب می شه).

step 4: step 2 و 3 را تازمانی که k centroid (و cluster) پیدا شوند ادامه بدهد.

روش دیگر، Word's method

است. این یک روش hierarchical clustering است و می توانیم آن را به جاس

که داده ها آن زیاد بودند، روش sample از آن انجام داد. پس mean های k cluster، همان initial centroids هستند.

Question 3)

در خوشه‌بندی در الگوریتم DBSCAN نقاط به نام core و border داریم که بر اساس معیارهای فاصله و تعداد همسایگانی (Eps) تعیین می‌شوند. یک نقطه core قرار می‌گیرد که در دایره نقطه border قرار می‌گیرد. است که density-reachable به نقطه‌ای Core باشد یعنی باید در محدوده فاصله‌های (distance threshold) از آن قرار گرفته باشد تا بتواند با آن در یک cluster قرار بگیرد.

الگوریتم DBSCAN می‌تواند non-linearly separable هم باشد یعنی خوشه‌های با arbitrary shape را هم می‌تواند خوشه‌بندی کند و بیشترین ویژگی خاصیتش توزیع داده‌ها را دارد.

الگوریتم DBSCAN اتفاقاً دارای time complexity $O(n \log n)$ است که به این دلیل است.


این ویژگی در دایره‌های از نقاط به الگوریتم DBSCAN نسبت به الگوریتم k-means است. در k-means درست نیست که k داریم ولی در DBSCAN نه. چون به صورت dynamically خوشه‌بندی را انجام می‌دهد.

این الگوریتم نسبت به noise و outlier دراز robustness است زیرا به هنگام کلاسترینگ، این نقاط را جزو نقاط core و border که در خوشه‌بندی لحاظ می‌شوند، قرار نمی‌دهد و در دایره چون نقاط outlier با نقاط core density-reachable نیستند، در یک خوشه قرار داده نمی‌شوند. پس DBSCAN نسبت به این نقاط، robust و مقاوم است.

Question 4) Hierarchical Agglomerative Clustering (HAC):

A)

$$\min \text{ distance} = \text{dist}(A, B) = 0.12 =$$



$$\Rightarrow \text{updating: } \min(\text{dist}(A, B), C) = \min(\text{dist}(A, C), \text{dist}(B, C)) = \min(0.15, 0.25) = 0.15$$

the distance

$$\Rightarrow \min(\text{dist}(A, B), D) = \min(\text{dist}(A, D), \text{dist}(B, D)) = \min(0.18, 0.14) = 0.14$$

$$\Rightarrow \min(\text{dist}(A, B), E) = \min(\text{dist}(A, E), \text{dist}(B, E)) = \min(0.28, 0.17) = 0.17$$

$$\Rightarrow \min(\text{dist}(A, B), F) = \min(\text{dist}(A, F), \text{dist}(B, F)) = \min(0.34, 0.41) = 0.34$$

E

$$((A, B), (C, D)), F)$$

E

0 / YΛ

ما سبقه في العلم


: دو باره با مد وصل

$$f_{\text{max}}(0, 1, 0) :$$

\Rightarrow updating: $\min \text{dist}(\overbrace{((A, B), (C, D)), F}, E) =$
the distance


در مداخل T و E باید که دما و پتانسیل شیمیایی ثابت باشد.

⇒ Complete dendrogram given :
 ممتد کامل درخت



B) 1. here max & min updating complete link method is used.
 در اینجا بیشینه و کمینه به روش لینک کامل استفاده شده است.

min distance = dist (A, B) = 0.12 =)



⇒ updating : max (dist (A, B), C) = max ((A, C), (B, C)) = max (0.15, 0.25) = 0.25
 the distance

⇒ max (dist (A, B), D) = max ((A, D), (B, D)) = max (0.18, 0.14) = 0.18


⇒ max (dist (A, B), E) = max ((A, E), (B, E)) = max (0.28, 0.22) = 0.28

⇒ max (dist (A, B), F) = max ((A, F), (B, F)) = max (0.35, 0.41) = 0.41

⇒

	(A, B), F	(C, D), E	E, F, F
(A, B), F	0		
(C, D)	0.18	0	
(C, D), E	0.28	0	0
E	0.28	0.28	0
F	0.41	0.41	0.41

$\Rightarrow \min \text{ distance} = \text{dist}(C, D) = 0,14 \Rightarrow$




\Rightarrow updating:
the distance

$\max(\text{dist}(C, D), (A, B)) = \max((A, B), C), ((A, B), D)) = \max(0,21, 0,14) = 0,14$

$\Rightarrow \max(\text{dist}(C, D), E) = \max(\text{dist}(C, E), (D, E)) = \max(0,10, 0,20) = 0,10$

$\Rightarrow \max(\text{dist}(C, D), F) = \max(\text{dist}(C, F), (D, F)) = \max(0,14, 0,20) = 0,14$

$\Rightarrow \min \text{ distance} = \text{dist}((A, B), F) = 0,14 \Rightarrow$



\Rightarrow updating:
the distance

$\max(\text{dist}((A, B), F), (C, D)) = \max(((A, B), F), (F, (C, D))) = \max(0,14, 0,10) = 0,14$

$\Rightarrow \max(\text{dist}((A, B), F), E) = \max(((A, B), E), (F, E)) = \max(0,17, 0,14) = 0,17$


$\Rightarrow \min \text{ distance} = \text{dist}((C, D), E) = 0,10 \Rightarrow$



\Rightarrow updating:
the distance

$\max(\text{dist}((C, D), E), ((A, B), F)) = \max(((C, D), ((A, B), F)), (E, ((A, B), F))) = \max(0,14, 0,17) = 0,14$

\Rightarrow merge the two clusters, and the new distance is 0,14




\Rightarrow

dendrogram is:

\Rightarrow

the distance between the two clusters is 0,14



Question 5)


چون در شکل (A) داده‌ها به صورت linearly separable نیستند، و پیرامونی شان به صورت density based است، پس روش k means را نمی‌توان استفاده کرد.

A) DBSCAN →

زیرا در این جا داده‌ها هم linearly separable هستند و هم به صورت density based پس از هر دو روش k means, DBSCAN خوشه بندی می‌توان استفاده کرد.

B) هر دو روش →


: یک نمونه خرد بین
خطی با k means
می‌تواند به صورت متقابل
باشد.



چون ما به صورت قبل، داده‌ها هم linearly separable هستند و هم به اساس توزیع density در کنار هم قرار گرفته‌اند پس می‌توان از هر دو روش استفاده کرد.

C) هر دو روش →

: یک نمونه
جداسازی
خطی



در اینجا چون داده‌ها به صورت صفید و غیر خطی توزیع شده‌اند، پس قابل جداسازی خطی نیستند.

D) DBSCAN →

پس فقط الگوریتم DBSCAN که بر اساس density داده‌ها کاری کند، می‌توان استفاده کرد.